

# Mini-Projet Statistique

ZHAO Fubang(Group 4)

19:45:28 25 oct 2016

Je vous prie par avance de me pardonner si je commets des erreurs en français.

## Exercice 1

```
set.seed(42,kind = "Marsaglia-Multicarry")
```

### 1.1

Le  $g(\theta)$  pour  $0 < \theta < 1$  est

$$\begin{aligned} g(\theta) &= \sum_{k=1}^{+\infty} k\theta(1-\theta)^{k-1} \\ &= \theta \sum_{k=1}^{+\infty} -\frac{\partial(1-\theta)^k}{\partial x_1} \\ &= -\theta \frac{1}{\partial\theta} \left( \frac{1}{1-(1-\theta)} \right) \\ &= \frac{1}{\theta} \end{aligned}$$

### 1.2

Par le mesure de comptage sur  $\mathbb{N}^* = \{1, 2, 3, \dots\}$  le modèle est dominé. Parce que  $\mathbb{N}^* = \{1, 2, 3, \dots\}$  est dénombrable.

### 1.3

Car le modèle  $\{P\theta, \theta \in ]0, 1[ \}$  est régulier, on a

$$\text{var}_\theta[T(x)] \geq \frac{g'(\theta)^2}{I(\theta)}$$

Et la variance de  $T(x)$  est

$$\begin{aligned} \text{var}_\theta[T(x)] &= \text{var}_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \text{var}_\theta(x_1) \\ &= \frac{1-\theta}{n\theta^2} \end{aligned}$$

Car  $(X_1, \dots, X_n)$  sont  $n$  v.a. *i.i.d.* au sens des hypothèses du théorème de Cramér-Rao, la quantité d'information de Fisher est

$$\begin{aligned}
I(\theta) &= nI_1(\theta) = n\mathbb{E}_\theta[(\frac{\partial \log \theta (1-\theta)^{k-1}}{\partial \theta})^2] \\
&= n\mathbb{E}_\theta[(\frac{1}{\theta} - \frac{k-1}{1-\theta})^2] \\
&= n\text{var}(\frac{k-1}{1-\theta}) \\
&= \frac{n\text{var}(x)}{(1-\theta)^2} \\
&= \frac{n}{(1-\theta)\theta^2}
\end{aligned}$$

Et le paramètre d'intérêt  $g(\theta)$  est

$$g(\theta) = \mathbb{E}_\theta(T(x)) = \mathbb{E}_\theta(X_1) = \frac{1}{\theta}$$

On peut conclure: l'estimateur  $T(X)$  de  $g(\theta)$  est non biaisé et vérifie

$$\text{var}_\theta[T(x)] = \frac{g'(\theta)^2}{I(\theta)}$$

Donc  $T(X)$  atteint la borne de Cramér-Rao, C'est à dire,  $T(x)$  est un estimateur UVMB.

#### 1.4

Le risque quadratique de  $S_h$  est

$$\begin{aligned}
R(\theta, S_h) &= \mathbb{E}_\theta[(g(\theta) - S_h(X))^2] \\
&= \mathbb{E}_\theta[(\frac{1}{\theta} - hT(X))^2] \\
&= \frac{1}{\theta^2} - \frac{2h}{\theta^2} + h^2(\frac{1}{\theta^2} + \text{var}(T(X))) \\
&< R(\theta, T) = \text{var}(T(X))
\end{aligned}$$

C'est à dire:

$$\theta^2(h^2 - 1)\text{var}(T(X)) + (h - 1)^2 < 0$$

Si  $h > 1$ , on a

$$h \text{ n'existe pas}$$

Si  $h < 1$ , on a

$$\frac{n-1+\theta}{n+1-\theta} < h < 1$$

Alors quand on a  $\frac{n-1+\theta}{n+1-\theta} < h < 1$ , on va avoir  $R(\theta, S_h) < R(\theta, T)$ . Parce que  $R = \frac{1}{\theta^2} - \frac{2h}{\theta^2} + h^2(\frac{1}{\theta^2} + \text{var}(T(X)))$  est une fonction quadratique. Donc évidemment,


$$h^*(\theta) = \frac{1}{\theta^2 \text{var}(T(X)) + 1} = \frac{n}{n+1-\theta}$$

#### 1.5

Car  $h^*(\theta) = \frac{1}{\theta^2 \text{var}(T(X)) + 1} = \frac{n}{n+1-\theta}$ , c'est à dire  $h^*$  est une fonction de  $\theta$ , donc il n'existe pas  $h^*$  qui minimise le risque quadratique uniformément en  $\theta$ .

## 1.6

```
#Exercice1
#a
h = 10/(11-0.2)
theta_0 = 0.2
n = 10
M = 10**5
Z = matrix(nrow = n, ncol = M)
for(i in 1:M)
{
  v= rgeom(10, theta_0)
  Z[,i] = matrix(v, nrow=10)+1
}
#b
Tx = colMeans(Z)
Sx = h*Tx
#c
hist(Sx, col = "red", probability = TRUE,
     main = "Histogramme de Tx et Sx", breaks = 50,
     xlab = "Estimations Sx et Tx de g(theta)",
     ylab = "Probabilite")
hist(Tx, col = "blue", probability = TRUE, add = TRUE,
     density = 15, breaks = 50)
abline(v = 1/theta_0, lwd = 3)
legend("topright", lwd = 2,col = c("red", "blue", "black"),
      legend = c("Sx", "Tx","g(theta)"))
```



```
mean(Sx)
```

```
## [1] 4.627897
```

```
mean(Tx)
```

```
## [1] 4.998129
```

```
#d
```

```
L1 = (Tx-mean(Tx))**2
```

```
Lh = (Sx-mean(Tx))**2
```

```
#e
```

```
#R(theta_0,T)
```

```
(1-theta_0)/(n*(theta_0**2))
```

```
## [1] 2
```

```
#R(theta_0,S)
```

```
(1/theta_0**2+(1-theta_0)/(n*(theta_0**2)))*h**2-(2/theta_0**2)*h+1/theta_0**2
```

```
## [1] 1.851852
```

```
mean(L1)#l'approximation de R(theta_0,T)
```

```
## [1] 1.992093
```

```
mean(Lh)#l'approximation de R(theta_0,S)
```

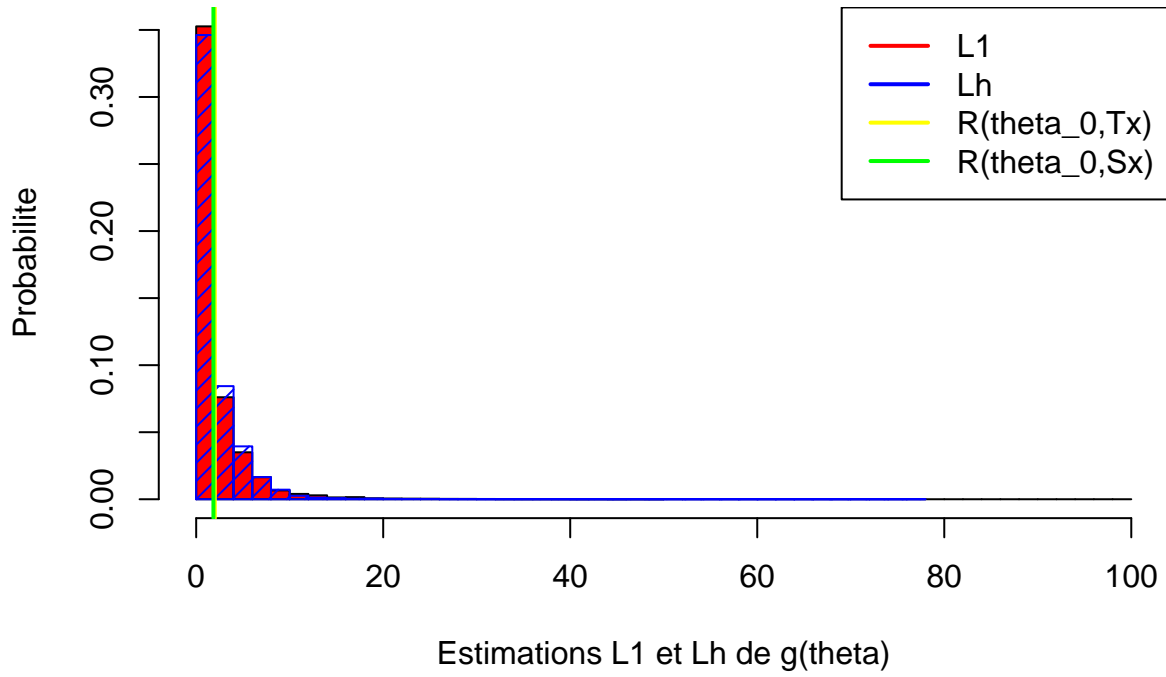
```
## [1] 1.84497
```

Avec  $h = \frac{10}{11-0.2}$ , qui est inclus dans  $\frac{n-1+\theta}{n+1-\theta} < h < 1$ , on a toujours  $R_S < R_T$ . Cela, même pour les estimations, est confirmé à la conclusion de la question 4.

```
#f
```

```
hist(L1, col = "red",  
     probability = TRUE,  
     main = "Histogramme de L1 et Lh",  
     breaks = 50,  
     xlab = "Estimations L1 et Lh de g(theta)",  
     ylab = "Probabilite")  
hist(Lh, col = "blue", probability = TRUE, add = TRUE,  
     density = 15, breaks = 50)  
abline(v = mean(L1), lwd = 2, col = "yellow")  
abline(v = mean(Lh), lwd = 2, col = "green")  
legend("topright", lwd = 2, col = c("red", "blue", "yellow", "green"),  
     legend = c("L1", "Lh", "R(theta_0,Tx)", "R(theta_0,Sx)"))
```

## Histogramme de L1 et Lh



## Exercice 2

### 2.1

Car le résultat est à nouveau une loi Beta, dont on doit préciser les paramètres

$$\begin{aligned}
 \pi(\theta|x) &= \frac{p_\theta(x)\pi(\theta)}{m(x)} \\
 &\propto p_\theta(x)\pi(\theta) \\
 &= \prod_{i=1}^n p_\theta(x_i)\pi(\theta) \\
 &= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} \theta^n (1 - \theta)^{\sum_{i=1}^n x_i - n} \\
 &= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha+n-1} (1 - \theta)^{\beta + \sum_{i=1}^n x_i - n - 1}
 \end{aligned}$$

Donc  $\pi(\theta|x)$  est une loi Beta:  $Beta(\alpha + n, \beta + \sum_{i=1}^n x_i - n)$ .

### 2.2

$$\mathbb{E}_\pi(\theta|x) = \frac{\alpha + n}{\alpha + \beta + \sum_{i=1}^n x_i}$$

Car  $\mathbb{E}_\pi(\theta|x)$  est une fonction de  $X$ , on peut considérer  $M(X) = E_\pi(\theta|X)$  comme un estimateur de  $\theta_0$ .

## 2.3

$$\mathbb{E}_\pi(\theta|x) = \frac{\frac{\alpha}{n} + 1}{\frac{\alpha+\beta}{n} + \frac{1}{n}\sum_{i=1}^n x_i}$$

Car la loi des grands nombres, lorsque  $n \rightarrow +\infty$ ,  $\mathbb{E}_\pi(\theta|x) \rightarrow \frac{1}{\bar{X}} = \frac{1}{\frac{1}{\theta}} = \theta$ .

Donc  $M_n = \mathbb{E}_\pi(\theta|X^n)$  converge  $\mathbb{P}_{\theta_0}$  - *presque* sûrement vers  $\theta_0$ .


## 2.4

```
#Exercice2
#a
grille = seq(0, 1, by = 0.01)
L = length(grille)
grille = grille[-c(1,L)]
x= rgeom(500, 0.6)+1
#b
n_pi = 500
v_beta = dbeta(grille, 1/2+n_pi, 3/2-n_pi+sum(x[1:n_pi]))
sp = spline(grille, v_beta, n=1000)
plot(sp,type="l", col="red", xlab = "Theta", ylab = "Beta",
     main = "Le Densite Des Loies")
n_pi = 100
v_beta = dbeta(grille, 1/2+n_pi, 3/2-n_pi+sum(x[1:n_pi]))
sp = spline(grille, v_beta, n=1000)
lines(sp, type="l", col="green")
n_pi = 20
v_beta = dbeta(grille, 1/2+n_pi, 3/2-n_pi+sum(x[1:n_pi]))
sp = spline(grille, v_beta, n=1000)
lines(sp, type="l", col="yellow")
n_pi = 5
v_beta = dbeta(grille, 1/2+n_pi, 3/2-n_pi+sum(x[1:n_pi]))
sp = spline(grille, v_beta, n=1000)
lines(sp, type="l", col="blue")

v_pi = dbeta(grille, 1/2, 3/2)
sp = spline(grille, v_pi, n=1000)
lines(sp, type="l", col="black")

abline(v=0.6, col="grey", lwd = 3)
legend("topright", lwd = 2,col = c("blue", "yellow", "green", "red", "black", "grey"),
     legend = c("n=5", "n=20", "n=100", "n=500", "pi(theta)","theta_0"))
```


## Le Densite Des Lois



On peut voir que, lorsque  $n$  est plus grand, l'espérance s'approche plus du vrai paramètre  $\theta_0$  et la courbe est plus proche de la ligne de  $\theta_0$ .

```
#c
E_theta_x = (1/2+(1:500))/(2+cumsum(x[1:500]))
sp = spline(1:500, E_theta_x, n=1000)
plot(sp,type="l", col="red", xlab = "n", ylab = "Theta",
      main = "L'esperance A Posteriori")
abline(h=0.6)
```

## L'esperance A Posteriori



On peut voir que, lorsque  $n$  augmente, l'esperance a posteriori converge vers le vrai  $\theta_0 = 0.6$ .

### Exercice 3

#### 3.1

L'espace des paramètres  $\Theta$  du modèle est  $\Theta = \{\mu \geq 0\}$ ,  $\Theta_0 = \{\mu = 0\}$ ,  $\Theta_1 = \{\mu > 0\}$ .

#### 3.2

On a

$$S_n(X) \sim \mathcal{N}(\mu, \delta^2)$$

On a  $\mathbb{E}_{H_0}[S_n(X)] = 0$ ,  $\text{var}_{H_0}(S_n(X)) = \frac{1}{n}$ , donc la loi de  $S_n(X)$  est

$$S_n(X) \sim \mathcal{N}(0, \frac{1}{n})$$

On a

$$\sqrt{n}S_n(X) \sim \mathcal{N}(\mu, \delta^2)$$

On a  $\mathbb{E}_{H_0}[\sqrt{n}S_n(X)] = 0$ ,  $\text{var}_{H_0}(\sqrt{n}S_n(X)) = 1$ , donc la loi de  $\sqrt{n}S_n(X)$  est

$$\sqrt{n}S_n(x) \sim \mathcal{N}(0, 1)$$

Pour que la probabilité de rejeter à tort  $H_0$  soit inférieure ou égale à  $\alpha = 5/100$ , on a

$$\int_{-\infty}^{\sqrt{n}A} p(\sqrt{n}S_n(x)) d(\sqrt{n}S_n(x)) \geq 1 - \frac{0.05}{2} = 0.975$$



Donc

$$A = \frac{F^{\leftarrow}(0.975)}{\sqrt{n}}$$

### 3.3

```
#Exercice3
#3
a = 0.05
p_a = 1-(a/2)
A_10 = qnorm(p_a,sd = 1/10**0.5)
A_100 = qnorm(p_a,sd = 1/100**0.5)
A_1000 = qnorm(p_a, sd = 1/1000**0.5)
A_10;A_100;A_1000
```

```
## [1] 0.619795
```

```
## [1] 0.1959964
```

```
## [1] 0.0619795
```

### 3.4

L'espérance de  $X$  est

$$\mathbb{E}(x) = \mathbb{E}(e^{\log x}) = \int_0^{+\infty} e^{\log x} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right) d(\log x)$$

On utilise  $y$  à remplacer  $\log x$ , donc

$$\begin{aligned} \mathbb{E}(x) &= \int_0^{+\infty} e^{\log x} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right) d(\log x) \\ &= \int_{-\infty}^{+\infty} e^y \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right) dy \\ &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - (\sigma^2 + 2\mu))^2}{2\sigma^2} + \frac{\sigma^2}{2} + \mu\right) dy \\ &= e^{\mu + \frac{\sigma^2}{2}} \end{aligned}$$

Car  $\sigma^2 = 1$ , on a:

$$\mathbb{E}(x) = e^{\mu + \frac{1}{2}}$$

```
#4
exp(0.1+0.5)
```

```
## [1] 1.822119
```


### 3.5

```

#5
grille_risque = seq(50,5000,200)
R_H1 = c()
for (n_3 in grille_risque)
{
  s = pnorm(qnorm(p_a,sd = 1/n_3**0.5), mean = 0.1, sd=1/n_3**0.5)
  b = pnorm(-qnorm(p_a,sd = 1/n_3**0.5), mean = 0.1, sd=1/n_3**0.5)
  v= s-b
  R_H1 = append(R_H1, v)
}
sp = spline(grille_risque, R_H1, n=1000)
plot(sp,type="l", col="red", xlab = "n", ylab = "R_H1",
      main = "Risque De Deuxieme Espece")
abline(h=0.05)

```

## Risque De Deuxieme Espece



```

n_0 = 0
for (n_3 in grille_risque) {
  s = pnorm(qnorm(p_a,sd = 1/n_3**0.5), mean = 0.1, sd=1/n_3**0.5)
  b = pnorm(-qnorm(p_a,sd = 1/n_3**0.5), mean = 0.1, sd=1/n_3**0.5)
  v= s-b
  if(v<=0.05)
  {
    n_0 = n_3
    break
  }
}
n_0

```

```
## [1] 1450
```

Donc pour  $n$  variant de 50 à 5000, sur une grille de pas  $h = 200$ , on a la première approximation de la plus petite valeur de  $n_0 = 1450$ .

### 3.6

```
#6
for (n_3 in 1:5000) {
  s = pnorm(qnorm(p_a, sd = 1/n_3**0.5), mean = 0.1, sd=1/n_3**0.5)
  b = pnorm(-qnorm(p_a, sd = 1/n_3**0.5), mean = 0.1, sd=1/n_3**0.5)
  v= s-b
  if(v<=0.05)
  {
    n_0 = n_3
    break
  }
}
n_0
```

```
## [1] 1300
```

Donc la valeur exacte de  $n_0$  est 1300.